

Sistemi e Applicazioni Cloud

Appello del 20 febbraio 2025 [Tempo consegna: 2h 30m]

Parte 1: rete base

Si usa un simulatore per studiare il comportamento di un sistema in grado di parallelizzare il traffico su diversi nodi.

Il sistema è mostrato nella figura.




Figure 1: Modello di rete

Il carico in ingresso è $\lambda = 100$ richieste al secondo e viene ripartito equamente tra gli N server (politica *round-robin* o *random* a piacere). I server hanno capacità di servizio $\mu_1 = 10$ richieste/sec. Il tempo di servizio segue una distribuzione lognormal con coefficiente di variazione $cv = 3$. Il processo di servizio delle richieste è vincolato ad un SLA sul tempo di risposta medio T_r che deve restare al di sotto di 250 ms.

Testare il tempo di servizio per $N = 20$ indicando anche l'intervallo di confidenza del 65% [$\approx 600ms$].

N	T_r	\pm CI
20	0.64264	± 0.00173

Parte 2: dimensionare il bilanciamento

Identificare mediante la teoria delle reti di code il valore di N tale per cui il requisito di SLA soddisfatto

$$\frac{1}{10} \cdot \left(1 + \frac{10}{x} \cdot (1 + 9) \right) = 0.25$$

Soluzione

$$x = \frac{130}{3}$$

Decimale
 $x = 43.33333\dots$

N	T_r
20	0.64264

Parte 3: verifica

Eseguire un'analisi del tempo di risposta per un range di valori di $N \in [15, 20, 25, 30, 35, 40, 45, 50]$.

N	T_r	\pm CI
15	1.05654	± 0.00423
20	0.64244	± 0.00147
25	0.41393	± 0.00119
30	0.35414	± 0.000566
35	0.29447	± 0.0003616
40	0.2626	± 0.0010503
45	0.2446	± 0.00236165
50	0.2248	± 0.00255608

Punto bonus: realizzare plot dei dati sulla base dell'esempio fornito




Figure 2: Plot